

■ Cours Express — Catégorie 3

■ LLM Evals, Tracing & Guardrails (Mistral FDE - PRIORITÉ #2)

1. ■■ LLM-as-a-Judge & Guardrails Synchrone vs Asynchrone

A. Évaluation Bloquante (LLM-as-a-Judge) dans le Chemin Critique

Problème : Exécuter un second appel LLM-as-a-Judge de manière synchrone pendant que l'utilisateur attend.

Impact Scalabilité : Ajoute systématiquement +2 à +5 secondes de latence synchrone sur chaque réponse.

■ Code Buggué	■ Correction Propre
<pre>@app.post('/generate') async def generate(req: Request): res = await llm.generate(req.prompt) is_safe = await llm_judge(res) # ■ Latence catastrophique ! return res</pre>	<pre>@app.post('/generate') async def generate(req: Request): res = await llm.generate(req.prompt) run_fast_regex_guardrails(res) # ■ Synchrone léger (<1ms) background_tasks.add_task(async_llm_judge, res) # ■ Async return res</pre>

B. Non-reproductibilité des Benchmarks Evals (Graines d'Aléatoire)

Problème : Exécuter des tests d'évaluation avec temperature=0.7 sans fix de seed.

Impact CI/CD : Empêche la détection de régressions dans les pipelines de déploiement continu.

■ Code Buggué	■ Correction Propre
<pre>def run_eval_suite(): # ■ Variabilité non reproductible ! return client.chat.complete(model='mistral-small', temp=0.7)</pre>	<pre>def run_eval_suite(): # ■ Inférence déterministe return client.chat.complete(model='mistral-small', temp=0.0, seed=42)</pre>

2. ■ Tracing & Typage des Métriques

A. Incohérence du Tracing dans les Agents Multi-étapes

Problème : Logger chaque sous-étape sans lier un trace_id ou session_id commun.

Impact Structure : Impossible de reconstruire l'arbre d'exécution ou de profiler la latence par sous-outil.

■ Code Buggué	■ Correction Propre
<pre>def execute_step(step_name: str): logger.info(f'Step {step_name} executed') # ■ Aucun lien de trace !</pre>	<pre>def execute_step(step_name: str, trace_id: str): with tracer.span(name=step_name, trace_id=trace_id): logger.info(f'Step {step_name}', extra={'trace_id': trace_id})</pre>

■ Réflexes Oraux pour l'Entretien Mistral (Jour J)

1. **'Garder le LLM-as-a-Judge hors du chemin critique'** → Préférer des Guardrails déterministes légers en synchrone et le Judge en asynchrone.
2. **'Reproductibilité des Evals'** → Forcer `temperature=0.0` et `seed=42` pour valider les non-régressions en CI/CD.
3. **'Propager le `trace\_id`'** → Tout log ou span d'agent doit partager un identifiant unique de session pour l'observabilité.
4. **'Critères Binaires Atomiques (Pass/Fail)'** → Bannir les échelles de Likert 1-5 floues au profit de vérifications booléennes typées Pydantic.